

Thesis econometrisch uitgelegd

Een leerdokument voor defense-voorbereiding

HAR-RS-DOW variance forecasting voor BTC-EUR

Sake Saakstra

MSc Econometrics & Operations Research — Financial Track

Vrije Universiteit Amsterdam

2025–2026

Samenvatting

Dit document is een pedagogische walkthrough van het HAR-RS-DOW thesis-project: van de econometrische intuïtie achter heterogeneous autoregressive volatility-modellen, via de wiskundige formulering, naar concrete Python-implementaties en hun financiële toepassingen in risk-management en option-pricing. Veertien zelfstandig leesbare hoofdstukken dekken alle onderdelen die in een defense-discussie aan bod kunnen komen.

Inhoudsopgave

1	Waarom HAR überhaupt?	2
1.1	Intuïtie	2
1.2	Wiskunde (basis-idee)	2
1.3	Python implementatie (HAR-basis)	2
1.4	Financiële toepassing	3
2	Realized variance	3
2.1	Intuïtie	3
2.2	Wiskunde (signature plot)	3
2.3	Python implementatie	4
2.4	Onze empirische bevinding (B1 signature plot)	4
3	Het HAR-model	5
3.1	Intuïtie verdiept	5
3.2	Waarom werkt het ondanks de eenvoud?	5
3.3	Wiskunde — autocovariance	5
4	HAR-RS (semivariance)	5
4.1	Intuïtie	5
4.2	Wiskunde	6
4.3	Python implementatie	6
5	HAR-RS-DOW	6

5.1	Intuïtie	6
5.2	Wiskunde	6
5.3	Python (extending HAR features)	7
6	Schatten van HAR	7
6.1	Intuïtie	7
6.2	Heteroskedasticiteit?	8
6.3	Multi-step forecasts ($h > 1$)	8
7	Density forecasting	8
7.1	Intuïtie	8
7.2	Wiskunde — Hansen 1994 skewed-t	8
7.3	MLE voor parameters	9
7.4	Onze empirische schatting	9
8	Walk-forward evaluatie	9
8.1	Intuïtie	9
8.2	Wiskunde — expanding vs rolling	10
8.3	Python (vereenvoudigd)	10
9	Scoring rules	11
9.1	Intuïtie	11
9.2	A. RMSE — mean prediction accuracy	11
9.3	B. QLIKE — proper voor variance	11
9.4	C. CRPS — full density evaluation	11
9.5	Onze resultaten ($n = 1\,312$)	11
10	Diebold-Mariano test	12
10.1	Intuïtie	12
10.2	Wiskunde	12
10.3	Python	12
10.4	Onze resultaten	13
11	Value-at-Risk	13
11.1	Intuïtie	13
11.2	Wiskunde	13
11.3	Backtest: Christoffersen	13
11.4	Onze resultaten (log-RV niveau)	14
12	Expected Shortfall	14
12.1	Intuïtie	14
12.2	Wiskunde — closed-form voor Student-t	14
12.3	Acerbi-Szekely (2014) Z1-test	14
12.4	Onze resultaten	15

13 Black-Scholes met HAR-	15
13.1 Intuïtie	15
13.2 Wiskunde	15
13.3 Python implementatie	16
13.4 Toepassing: HAR- als input	16
13.5 Onze resultaten	16
14 Vol-managed strategies	16
14.1 Intuïtie	16
14.2 Wiskunde	16
14.3 Onze empirische resultaten	17
15 Samenvatting voor je defense	17
15.1 De drie kern-bewijzen voor je commissie	17
15.2 Verwachte vragen + antwoorden	17
16 Belangrijkste literatuur — citeer deze in je defense	18

1 Waarom HAR überhaupt?

1.1 Intuïtie

Vol is niet random. Het clustert in tijd (Mandelbrot 1963: “large changes tend to be followed by large changes”). Maar GARCH-modellen capteren dit met één geheugenparameter. De realiteit van financiële markten is **veelschaliger**:

- **Intraday traders** reageren op tick-veranderingen — hun vol-update gaat in minuten
- **Day traders** reageren op dagelijkse closes — hun update in dagen
- **Wekelijkse portfolio managers** herbalanceren wekelijks — update in dagen-tot-weken
- **Maandelijks institutionele flows** komen door met maand-cadens

Müller et al. (1997) stelden voor: een vol-model moet **meerdere tijdsschalen tegelijk** capteren. Dit is de *Heterogeneous Market Hypothesis*: vol op één schaal beïnvloedt vol op andere schalen via deze verschillende marktparticipanten.

Corsi (2009) implementeerde dit eenvoudig: gebruik *daily*, *weekly* en *monthly* aggregaten van realized variance als drie regressoren. Geen fractionele integratie nodig, geen complexe ARFIMA-machinery — gewoon OLS op drie gemiddelden.

1.2 Wiskunde (basis-idee)

De realized variance RV_t op dag t is een schatting van de integrated variance op die dag:

$$IV_t = \int_{t-1}^t \sigma^2(s) ds$$

We willen voorspellen: $E[\log RV_{t+1} | \mathcal{F}_t]$

Corsi's voorstel:

$$\log RV_{t+1} = \beta_0 + \beta_d \log RV_t + \beta_w \overline{\log RV}_{t,t-4} + \beta_m \overline{\log RV}_{t,t-21} + \varepsilon_{t+1}$$

Met: $\overline{\log RV}_{t,t-4} = \frac{1}{5} \sum_{i=0}^4 \log RV_{t-i}$ (wekelijks gemiddelde) - $\overline{\log RV}_{t,t-21} = \frac{1}{22} \sum_{i=0}^{21} \log RV_{t-i}$ (maandelijks gemiddelde)

Waarom log? Twee redenen: (1) RV is rechts-scheef en heteroskedastisch, log maakt het bijna-normaal; (2) een lineair model op log-niveau is multiplicatief op het oorspronkelijke niveau, wat past bij vol-procesgedrag.

1.3 Python implementatie (HAR-basis)

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
```

```
def har_features(log_rv: pd.Series) -> pd.DataFrame:
    """Bouw HAR-features: daily, weekly, monthly aggregaten."""
    X = pd.DataFrame(index=log_rv.index)
    X['daily'] = log_rv.shift(1) # log RV_t
    X['weekly'] = log_rv.shift(1).rolling(5).mean() # 5-day avg
    X['monthly'] = log_rv.shift(1).rolling(22).mean() # 22-day avg
    return X

# Fit
log_rv = np.log(rv_series) # je realized variance series
X = har_features(log_rv).dropna()
y = log_rv.loc[X.index]

X_with_const = sm.add_constant(X)
model = sm.OLS(y, X_with_const).fit()
print(model.summary())
```

1.4 Financiële toepassing

Daily HAR- wordt direct gebruikt in: - **Vol-managed portfolios** (Moreira-Muir 2017): positie-grootte $1/_t$ - **Option pricing**: in Black-Scholes - **Risk-budgeting**: capital allocatie $_i^1$ - **VaR-modellen**: als input voor quantile-mapping

2 Realized variance

2.1 Intuïtie

Hoe meet je de “vol van dag t”? Naïef: variance van returns. Maar binnen één dag heb je véél returns (1440 minuut-returns!). Dus:

$$RV_t = \sum_{i=1}^N r_{t,i}^2$$

waar $r_{t,i}$ = i-de intraday return op dag t.

Maar er is een probleem: bij hoge frequenties (1-min) is RV biased door **microstructure noise**: - Bid-ask bounce: prijs danst tussen bid en ask - Tick-discretisation: prijzen zijn integer veelvouden van tick-size - Asynchrone trades op verschillende exchanges

Dit voegt valse “vol” toe die geen echte volatiliteit is.

2.2 Wiskunde (signature plot)

Theoretisch zou RV_t bij steeds hogere frequentie naar de echte IV_t moeten convergeren. **Maar empirisch** zien we het tegenovergestelde:

$$RV_t^{(\Delta)} \xrightarrow{\Delta \rightarrow 0} IV_t + \text{noise variance}$$

De signature plot toont RV als functie van sampling-frequentie. Bij ~5 minuten plateau-vorming = optimum tussen signal (meer data) en noise (microstructure).

Realized Kernel (Barndorff-Nielsen, Hansen, Lunde, Shephard 2008):

$$RK_t = \sum_{h=-H}^H k\left(\frac{h}{H}\right) \gamma_h(r)$$

Waarbij $\gamma_h(r) = \sum_i r_{t,i} r_{t,i-h}$ (autocovariance op lag h) en $k(\cdot) = \text{Parzen-kernel}$. Dit corrigeert voor noise door autocovariance-correctie.

2.3 Python implementatie

```
def realized_variance(returns, freq='5min'):
    """Simple RV per dag uit intraday returns."""
    grouped = returns.groupby(returns.index.date)
    return grouped.apply(lambda r: (r**2).sum())

def realized_kernel(returns, H=10):
    """Parzen-kernel realized kernel."""
    def parzen(x):
        ax = abs(x)
        if ax <= 0.5: return 1 - 6*x**2 + 6*ax**3
        elif ax <= 1: return 2*(1-ax)**3
        else: return 0

    def daily_rk(r):
        n = len(r)
        rk = (r**2).sum() # gamma_0
        for h in range(1, min(H, n)):
            gamma_h = (r.iloc[h:].values * r.iloc[:-h].values).sum()
            rk += 2 * parzen(h/H) * gamma_h
        return rk

    return returns.groupby(returns.index.date).apply(daily_rk)
```

2.4 Onze empirische bevinding (B1 signature plot)

Frequentie	Simple RV	Realized Kernel
1-min	33% bias	12% bias
5-min	10% bias	~10% bias (lager variance)
15-min	8% bias	8% bias

→ Wij gebruiken **RK @ 5-min** als primaire RV-meting voor BTC-EUR.

3 Het HAR-model

3.1 Intuïtie verdiept

HAR is geen black-box ML model. Het is een **lineaire regressie** met drie zorgvuldig gekozen regressoren. Het is dus volledig interpreteerbaar:

- β_d = “hoeveel weegt gisteren?” — meestal 0.30-0.50 voor crypto
- β_w = “hoeveel weegt de afgelopen week?” — meestal 0.20-0.35
- β_m = “hoeveel weegt de afgelopen maand?” — meestal 0.10-0.25

De som $\beta_d + \beta_w + \beta_m$ is bijna altijd < 1 (mean-reversion).

3.2 Waarom werkt het ondanks de eenvoud?

HAR is een **goede approximatie van long-memory** zonder de complexiteit van fractioneel geïntegreerde modellen (ARFIMA). Corsi toonde aan dat HAR's autocovariance-functie een **trage decay** heeft die empirisch waargenomen long-memory in vol nabootst.

GPH-estimator op log-RV BTC-EUR: $\hat{d} = 0.653 \rightarrow$ fractioneel geïntegreerd. HAR vangt dit met simpele OLS.

3.3 Wiskunde — autocovariance

De impliciete autocovariance van het HAR-proces:

$$\text{Cov}(\log RV_t, \log RV_{t+h}) = \beta_d \cdot \gamma(h-1) + \beta_w \cdot \frac{1}{5} \sum_{i=0}^4 \gamma(h-1-i) + \beta_m \cdot \frac{1}{22} \sum_{i=0}^{21} \gamma(h-1-i)$$

Deze decay is *hyperbolisch*-achtig (niet exponentieel) $\rightarrow$ mimics long-memory.

4 HAR-RS (semivariance)

4.1 Intuïtie

Niet alle volatiliteit is gelijk. **Negatieve return-vol is gevaarlijker** dan positieve return-vol: - Een crash van 5% voelt ergst dan een rally van 5% (loss aversion) - Negatieve returns voorspellen meer vol dan positieve (leverage effect: $r \downarrow \rightarrow \uparrow$) - Voor risk management: linker-staart matters more

Patton & Sheppard (2015) stelden voor om RV te splitsen in twee componenten:

4.2 Wiskunde

$$RS_t^+ = \sum_{i:r_{t,i}>0} r_{t,i}^2 \quad (\text{positive semivariance})$$

$$RS_t^- = \sum_{i:r_{t,i}<0} r_{t,i}^2 \quad (\text{negative semivariance})$$

Eigenschap: $RS_t^+ + RS_t^- = RV_t$

HAR-RS vervangt $\beta_d \log RV_t$ door **twee** termen:

$$\log RV_{t+1} = \beta_0 + \beta_d^+ \log RS_t^+ + \beta_d^- \log RS_t^- + \beta_w \overline{\log RV}_{t,t-4} + \beta_m \overline{\log RV}_{t,t-21} + \varepsilon$$

Empirische bevinding voor BTC-EUR: $\hat{\beta}_d^- = 0.34, \hat{\beta}_d^+ = 0.18 \rightarrow$ negative semivariance is bijna 2x informatiever dan positive. Dit is de leverage-effect op variance-niveau.

4.3 Python implementatie

```
def realized_semivariance(returns):
    """Splits RV in positief en negatief deel per dag."""
    def daily_split(r):
        pos = r[r > 0]
        neg = r[r < 0]
        return pd.Series({
            'RS_plus': (pos**2).sum(),
            'RS_minus': (neg**2).sum(),
            'RV': (r**2).sum() # sanity check
        })
    return returns.groupby(returns.index.date).apply(daily_split)
```

5 HAR-RS-DOW

5.1 Intuïtie

BTC handelt 24/7, ook in het weekend — maar institutionele flows niet. Empirisch: - **Weekend vol 37% lager** dan doordeweekse vol - **Maandag vol 14% hoger** (catch-up na weekend) - Klassiek “weekend effect” in volatiliteit

Dit is **systematisch en kalender-bepaald** — niet door HAR’s vol-aggregaten te vangen. Een day-of-week dummy lost dit op.

5.2 Wiskunde

Voeg 6 dummies toe (zondag = baseline):

$$\begin{aligned}\log RV_{t+1} = & \underbrace{\beta_0 + \beta_d^+ \log RS_t^+ + \beta_d^- \log RS_t^-}_{\text{semivariance terms}} \\ & + \beta_w \overline{\log RV}_{t,t-4} + \beta_m \overline{\log RV}_{t,t-21} \\ & + \sum_{k=1}^6 \gamma_k D_{k,t+1} + \varepsilon_{t+1}\end{aligned}$$

Waarbij:

$$D_{k,t+1} = \begin{cases} 1 & \text{als dag } t+1 \text{ is dag } k \\ 0 & \text{anders} \end{cases}$$

Onze schattingen voor BTC-EUR:

Dag (k)	$\hat{\gamma}_k$	Interpretatie
Maandag	+0.142	Catch-up vol
Dinsdag	+0.087	Normale weekdag
Woensdag	+0.063	Mid-week
Donderdag	+0.054	Normale weekdag
Vrijdag	+0.038	Lichte stijging
Zaterdag	0.281	Weekend stilte
Zondag (baseline)	0	—

5.3 Python (extending HAR features)

```
def har_rs_dow_features(log_rs_plus, log_rs_minus, log_rv):
    X = pd.DataFrame(index=log_rv.index)
    X['daily_plus'] = log_rs_plus.shift(1)
    X['daily_minus'] = log_rs_minus.shift(1)
    X['weekly'] = log_rv.shift(1).rolling(5).mean()
    X['monthly'] = log_rv.shift(1).rolling(22).mean()

    # DOW dummies (zondag = baseline, geen kolom)
    for day, name in enumerate(['Mon', 'Tue', 'Wed', 'Thu', 'Fri', 'Sat']):
        X[f'DOW_{name}'] = (X.index.dayofweek == day).astype(int)
    return X
```

6 Schatten van HAR

6.1 Intuïtie

HAR-modellen zijn lineair in parameters → **OLS is optimaal** (BLUE) als de residuen voldoen aan Gauss-Markov-voorwaarden. We schatten:

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

Waarbij $y = \log RV$ en $X = \text{HAR-features}$.

6.2 Heteroskedasticiteit?

Log-RV is bijna homoskedastisch (vandaar de keuze voor log). OLS-standaardfouten zijn doorgaans betrouwbaar. Voor zekerheid gebruiken we **Newey-West HAC standaardfouten** (lag = 5 voor weekly persistence):

```
import statsmodels.api as sm
model = sm.OLS(y, X).fit(cov_type='HAC', cov_kws={'maxlags': 5})
```

6.3 Multi-step forecasts ($h > 1$)

Voor h-stap vooruit voorspellen heb je twee opties: 1. **Iterated**: substitueer voorspelde waarden in voor onbekende future RVs 2. **Direct**: schat een aparte model per horizon

We gebruiken **direct** omdat het robuuster is voor lange horizons:

```
# Voor h=5 vooruit:
y_h5 = log_rv.shift(-5) # target is 5 dagen vooruit
X_t = har_features(log_rv)
model_h5 = sm.OLS(y_h5, X_t).fit()
```

7 Density forecasting

7.1 Intuïtie

HAR levert een **point forecast** $\hat{\mu}_t = E[\log RV_{t+1} | \mathcal{F}_t]$. Maar voor risk-applicaties hebben we de hele **conditional density** nodig: $p(\log RV_{t+1} | \mathcal{F}_t)$.

We modelleren residuen $\varepsilon_t = \log RV_t - \hat{\mu}_t$ via **Hansen 1994 skewed-t**:

7.2 Wiskunde — Hansen 1994 skewed-t

$$f(z; \nu, \lambda) = bc \left[1 + \frac{1}{\nu - 2} \left(\frac{bz + a}{1 - \lambda \cdot \text{sgn}(bz + a)} \right)^2 \right]^{-(\nu+1)/2}$$

Met: - $a = 4\lambda c \frac{\nu-2}{\nu-1}$ - $b^2 = 1 + 3\lambda^2 - a^2$ - $c = \Gamma\left(\frac{\nu+1}{2}\right) / \left[\sqrt{\pi(\nu-2)} \cdot \Gamma\left(\frac{\nu}{2}\right)\right]$

Parameters: - $\nu > 2$: degrees of freedom (lager = zwaardere staarten) - $\lambda \in (-1, 1)$: skewness (-1 = max linkerschef, +1 = max rechterschef)

7.3 MLE voor parameters

```
from scipy.special import gamma as gfn
from scipy.optimize import minimize

def hansen_skewt_pdf(z, eta, lam):
    c = gfn((eta+1)/2) / (np.sqrt(np.pi*(eta-2)) * gfn(eta/2))
    a = 4 * lam * c * (eta - 2) / (eta - 1)
    b = np.sqrt(1 + 3*lam**2 - a**2)
    z_thresh = -a/b
    return np.where(
        z < z_thresh,
        b * c * (1 + 1/(eta-2) * ((b*z + a)/(1 - lam))**2)**(-(eta+1)/2),
        b * c * (1 + 1/(eta-2) * ((b*z + a)/(1 + lam))**2)**(-(eta+1)/2))

def neg_log_lik(params, z):
    eta, lam = params
    if eta <= 2.01 or eta > 50 or abs(lam) >= 0.99: return 1e10
    pdf = hansen_skewt_pdf(z, eta, lam)
    return -np.sum(np.log(pdf + 1e-300))

# Fit on standardized residuals
result = minimize(neg_log_lik, x0=[5, 0], args=(z_residuals,), method='Nelder-Mead')
nu_hat, lambda_hat = result.x
```

7.4 Onze empirische schatting

Op **log-RV residuen** (residuen van HAR-RS-DOW): - $\hat{\nu} = 9.23$ (matige fat tails) - $\hat{\lambda} = +0.27$ (lichte rechterschef in log-RV)

Op **standaardized returns** $z_t = r_t/\hat{\sigma}_t$: - $\hat{\nu} = 4.37$ (zwaardere fat tails) - $\hat{\lambda} = +0.01$ 0 (symmetrisch — HAR- absorbeert de leverage)

Belangrijk inzicht: dat $\lambda \approx 0$ voor gestandaardiseerde returns is precies wat je wilt zien. Het betekent dat alle asymmetrie in BTC-returns *al gevangen wordt door HAR's tijdvariërende*. Geen extra correctie nodig voor skewness.

8 Walk-forward evaluatie

8.1 Intuïtie

Je kunt niet OOS-evalueren met een vast model — markten veranderen. **Walk-forward** simuleert hoe je het model in productie zou gebruiken:

1. Train op data tot t
2. Voorspel voor $t+1$
3. Schuif window één dag op

4. Refit periodiek (om de 20 dagen)

```
Train
Test
      t+1

Train
Test
      t+21
```

8.2 Wiskunde — expanding vs rolling

Expanding window (wij gebruiken dit): - Training-set groeit elke 20 dagen - Behoudt alle history (beter voor low-frequency data zoals dag)

Rolling window: - Vast venster van bijvoorbeeld 500 dagen - Vergeet oude data (beter bij regime-changes)

Voor BTC, sinds de markt fundamenteel veranderde post-2017 (institutionalization), is expanding-vanaf-2019 zinvol.

8.3 Python (vereenvoudigd)

```
def walk_forward(y, X, refit_step=20, train_start='2019-04-03', test_start='2022-10-01'):
    results = []
    test_dates = X.loc[test_start:].index

    # Init model
    train_mask = X.index < test_start
    model = sm.OLS(y[train_mask], X[train_mask]).fit()

    for i, t in enumerate(test_dates):
        # Refit elke 20 dagen
        if i % refit_step == 0:
            train_mask = X.index < t
            model = sm.OLS(y[train_mask], X[train_mask]).fit()

        # Voorspel
        y_hat = model.predict(X.loc[[t]]).iloc[0]
        results.append({'date': t, 'y_pred': y_hat, 'y_actual': y.loc[t]})

    return pd.DataFrame(results)
```

9 Scoring rules

9.1 Intuïtie

Hoe meet je hoe goed een **distributional forecast** is? Niet alleen mean-prediction telt — calibratie van de hele density.

Drie standaarden:

9.2 A. RMSE — mean prediction accuracy

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum (\hat{\mu}_t - y_t)^2}$$

Snel, gemakkelijk te interpreteren. Maar negeert calibratie.

9.3 B. QLIKE — proper voor variance

$$\text{QLIKE} = \log(\hat{\sigma}_t^2) + \frac{RV_t}{\hat{\sigma}_t^2}$$

Patton (2011): QLIKE is een *proper scoring rule* voor variance — kan niet “gegamed” worden door over-/onder-schatting. Robuust tegen RV-measurement-error.

9.4 C. CRPS — full density evaluation

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} [F(z) - \mathbb{I}\{z \geq y\}]^2 dz$$

Waarbij F = forecasted CDF, y = realisatie. **CRPS rewards both sharpness and calibration** — een proper scoring rule voor distributional forecasts.

Voor skewed-t density (analytische vorm bestaat niet, dus MC):

```
def crps_mc(y, samples):  
    """Monte Carlo CRPS gegeven samples uit forecast density."""  
    samples = np.sort(samples)  
    n = len(samples)  
    # CRPS = E|X - y| - 0.5 * E|X - X'|  
    term1 = np.mean(np.abs(samples - y))  
    term2 = 0.5 * np.mean(np.abs(samples[:, None] - samples[None, :]))  
    return term1 - term2
```

9.5 Onze resultaten (n = 1 312)

Model	CRPS ↓	QLIKE ↓	RMSE ↓	R ² _oos ↑
HAR-RS-DOW	0.498	0.595	0.889	+0.44
HAR-RS-Q-WE-X	0.582	0.725	0.948	+0.25
HAR-RS-X	0.585	0.742	0.952	+0.23
HAR-RS-WE	0.587	0.748	0.954	+0.23

Model	CRPS ↓	QLIKE ↓	RMSE ↓	R ² _oos ↑
HAR-WE	0.589	0.685	0.957	+0.22

HAR-RS-DOW wint op **alle vier** de metrics zonder uitzondering.

10 Diebold-Mariano test

10.1 Intuïtie

Verschillen in CRPS tussen twee modellen zijn empirisch — maar zijn ze **statistisch significant**? DM-test toetst of twee modellen even nauwkeurig zijn.

10.2 Wiskunde

Voor twee modellen A, B met loss-series L_t^A, L_t^B :

$$d_t = L_t^A - L_t^B$$

Onder H_0 (gelijke nauwkeurigheid): $E[d_t] = 0$.

DM-statistic:

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})/n}} \xrightarrow{d} N(0, 1)$$

Voor variance estimation gebruiken we **Newey-West HAC** (autocorrelatie in d_t corrigeren):

$$\widehat{\text{Var}}(\bar{d}) = \frac{1}{n} \left[\hat{\gamma}_0 + 2 \sum_{k=1}^K w_k \hat{\gamma}_k \right]$$

Met Bartlett-kernel $w_k = 1 - k/(K+1)$ en optimale lag $K = \lfloor 4(n/100)^{2/9} \rfloor$ (voor $n=1312$: $K=7$).

10.3 Python

```
def diebold_mariano(loss_a, loss_b, h=1):
    """DM-test met Newey-West HAC."""
    d = loss_a - loss_b
    n = len(d)
    mean_d = d.mean()

    # Newey-West variance
    K = int(np.floor(4 * (n/100)**(2/9)))
    var_d = ((d - mean_d)**2).mean()
    for k in range(1, K+1):
        cov_k = ((d[k:] - mean_d) * (d[:-k] - mean_d)).mean()
```

```

var_d += 2 * (1 - k/(K+1)) * cov_k

dm_stat = mean_d / np.sqrt(var_d / n)
p_value = 2 * (1 - stats.norm.cdf(abs(dm_stat)))
return dm_stat, p_value

```

10.4 Onze resultaten

HAR-RS-DOW vs ...	DM-statistic	p-value	Significantie
HAR-RS-Q-WE-X	-7.34	< 0.001	
HAR-RS-X	-7.51	< 0.001	
HAR-RS-WE	-7.42	< 0.005	
HAR-WE	-6.89	< 0.005	

Alle p-waarden ver onder 0.05 — HAR-RS-DOW is statistisch significant beter.

11 Value-at-Risk

11.1 Intuïtie

VaR_ = “Wat is het verlies dat we met waarschijnlijkheid (1-) niet zullen overschrijden?”

Voor =5% en =2% per dag (return-vol): - VaR_5% · 1.645 = 3.29% (Normal aanname) - Anders gezegd: 95% van de dagen is verlies < 3.29%

11.2 Wiskunde

$$\text{VaR}_\alpha(r_{t+1}|\mathcal{F}_t) = F_{r|\mathcal{F}_t}^{-1}(\alpha)$$

Voor verschillende density-aannames:

Normal: $\text{VaR}_\alpha = -\sigma_t \cdot z_\alpha$, met $z_\alpha = \Phi^{-1}(\alpha)$

Student-t(): $\text{VaR}_\alpha = -\sigma_t \cdot t_{\alpha,\nu} / \sqrt{\nu/(\nu-2)}$ (gestandaardiseerd)

Hansen skewed-t(): numerieke inversie van de skewed-t CDF

11.3 Backtest: Christoffersen

Onder correct model: violations $\mathbb{1}\{r_t < \text{VaR}_\alpha\}$ vormen i.i.d. Bernoulli().

Unconditional coverage test (Kupiec 1995):

$$LR_{uc} = -2 \log \left[\frac{\alpha^x (1-\alpha)^{n-x}}{(\hat{p})^x (1-\hat{p})^{n-x}} \right] \sim \chi_1^2$$

Met x = aantal violations, $\hat{p} = x/n$.

Conditional coverage test (Christoffersen 1998): test ook **independence** van violations (geen clusters).

11.4 Onze resultaten (log-RV niveau)

	Target	Realized	Coverage ratio	Kupiec p
1%	13	13	1.00	1.00
5%	65	67	1.03	0.81
95%	65	64	0.98	0.90
99%	13	12	0.92	0.78

Perfekte calibratie op log-RV niveau.

12 Expected Shortfall

12.1 Intuïtie

VaR vertelt je *waar* de staart begint. ES vertelt je *hoe erg* de staart wordt.

$$ES_\alpha = E[r_t | r_t \leq VaR_\alpha]$$

ES is **coherent risk measure** (Artzner et al. 1999) — VaR is dat niet (geen subadditiviteit).

Basel III FRTB (2016) vervangt VaR door ES als regulatory standard precies om deze reden.

12.2 Wiskunde — closed-form voor Student-t

Voor standardized Student-t():

$$ES_\alpha = -\frac{\nu + t_\alpha^2}{\nu - 1} \cdot \frac{f_\nu(t_\alpha)}{\alpha} \cdot \frac{1}{\sqrt{\nu/(\nu - 2)}}$$

Waarbij $t_\alpha = F_\nu^{-1}(\alpha)$ en f_ν de standard-t pdf.

Voor BTC- = 3%, =3, =5%:

$$ES_{5\%} = -0.03 \cdot 2.237 = -6.71\%$$

12.3 Acerbi-Szekely (2014) Z1-test

Hoe test je of ES-forecasts adequaat zijn? Christoffersen werkt niet voor ES (geen indicator-functie). Acerbi-Szekely Z1:

$$Z_1 = \frac{1}{N_\alpha} \sum_{t: \text{violation}_t} \frac{r_t}{\text{ES}_\alpha(t)} + 1$$

Onder H_0 (model correct): $E[Z_1] = 0$.

Interpretatie: - $Z_1 > 0 \rightarrow$ conservatief (realized losses minder erg dan voorspeld) - $Z_1 = 0 \rightarrow$ perfect kalibreerd - $Z_1 < 0 \rightarrow$ underforecast (gevaarlijk voor risk capital)

12.4 Onze resultaten

Density		Forecast ES	Realized ES	Z1	Verdict
Normal	1%	-5.93%	-5.84%	+2.11	Conservatief
Normal	5%	-4.59%	-3.91%	+1.90	Conservatief
Student-t(3)	1%	-8.99%	-5.84%	+1.73	Conservatief
Student-t(3)	5%	-4.97%	-3.91%	+1.83	Conservatief
Hansen skewed-t (=4.4)	1%	-7.86%	-5.84%	+1.83	Conservatief
Hansen skewed-t (=4.4)	5%	-5.06%	-3.91%	+1.81	Conservatief

ALLE drie density-aannames geven positieve Z1 $\rightarrow$ conclusie is robuust. HAR-driven ES is adequate voor Basel III kapitaal-reservering.

13 Black-Scholes met HAR-

13.1 Intuïtie

Black-Scholes (1973): de prijs van een Europese call is een functie van vijf inputs:

$$C(S, K, r, T, \sigma) = S\Phi(d_1) - Ke^{-rT}\Phi(d_2)$$

Vier van deze (spot S , strike K , rate r , time-to-maturity T) zijn observeerbaar. **is de enige onbekende** — en daarmee de meest waardevolle input.

13.2 Wiskunde

$$d_1 = \frac{\ln(S/K) + (r + \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}$$

Put-call parity:

$$P = C - S + Ke^{-rT}$$

ATM straddle ($K = S$, $r = 0$):

$$\text{Straddle} = C + P = 2 \cdot S \cdot \Phi(d_1) - S - S + S = 2S[\Phi(d_1) - 0.5]$$

Voor $d_{-1} = 0.5T$ (ATM, $r=0$), is straddle $0.8 \cdot S \cdot \sqrt{T}$.

13.3 Python implementatie

```
from scipy.stats import norm

def bs_call(S, K, sigma, T, r=0):
    d1 = (np.log(S/K) + (r + 0.5*sigma**2)*T) / (sigma*np.sqrt(T))
    d2 = d1 - sigma*np.sqrt(T)
    return S*norm.cdf(d1) - K*np.exp(-r*T)*norm.cdf(d2)

def bs_straddle_atm(S, sigma_daily, T_days):
    sigma_ann = sigma_daily * np.sqrt(365)
    T = T_days / 365
    call = bs_call(S, S, sigma_ann, T)
    put = call # ATM, r=0
    return call + put
```

13.4 Toepassing: HAR- als input

Voor elke dag t in OOS: 1. Compute HAR-forecast: $\hat{\sigma}_{t+1}$ 2. “Verkoop” een 7-day ATM straddle voor premium = BS(_HAR) 3. Wacht 7 dagen 4. Payoff = $|S_{t+7} - S_t|$ 5. P&L = Premium Payoff

13.5 Onze resultaten

-model	Avg premium	Avg payoff	Edge	Hit%
Constant	€11.16	€10.30	+€0.86	66.4%
Rolling 30d	€10.59	€10.30	+€0.29	63.0%
HAR-RS-DOW	€10.50	€10.30	+€0.20	60.0%

HAR- levert prijzen **dichtst bij fair value** — minst systematisch mispricing.

14 Vol-managed strategies

14.1 Intuïtie

Moreira-Muir (2017) toonden dat **dynamische positie-sizing op basis van vol** Sharpe-ratio's verhoogt: - Bij hoge σ_t : kleinere positie - Bij lage σ_t : grotere positie - Net effect: meer constante portfolio-vol → betere risk-adjusted return

14.2 Wiskunde

Vol-target strategie:

$$w_t = \min\left(w_{\max}, \frac{\sigma_{\text{target}}}{\hat{\sigma}_t}\right)$$

Bijvoorbeeld $\sigma_{\text{target}} = 35\%$ jaarlijks en $\hat{\sigma}_t$ uit HAR.

Portfolio return: $r_t^{\text{port}} = w_{t-1} \cdot r_t^{\text{asset}}$

14.3 Onze empirische resultaten

Strategie	Sharpe	MDD	Verdict
Pure HAR vol-target (daily)	0.36	-22%	Fees consumeren edge
HAR vol-target + Trend MA50	0.94	-26%	ROBUST
ATR-stop + Trend MA50	1.14	-28%	Winner (simpel beats HAR)
Buy-and-hold	0.52	-55%	FRAGILE in late period

Belangrijkste vondst: HAR voegt waarde toe als **position-sizing within a trend overlay**, niet als pure directional signal. Dit is consistent met theorie: HAR voorspelt magnitude, niet richting.

15 Samenvatting voor je defense

15.1 De drie kern-bewijzen voor je commissie

1. **Statistisch:** HAR-RS-DOW wint op CRPS, QLIKE, R^2 , DM — vier onafhankelijke metrics, alle $p < 0.005$
2. **Risk-management:** ES-coverage $Z1 = +1.7$ - 2.1 (conservatief) onder Normal, Student-t(3), én Hansen skewed-t. Robuust voor Basel III.
3. **Trading:** HAR's economische waarde is configuratie-afhankelijk. Vol-targeting + trend = ROBUST. Pure vol-managed wordt verslagen door eenvoudige ATR-stop.

15.2 Verwachte vragen + antwoorden

Q: “HAR-RS-DOW heb je zelf bedacht?” **A:** HAR (Corsi 2009) en HAR-RS (Patton-Sheppard 2015) zijn established. DOW-dummies zijn standaard econometrie. Onze bijdrage is de **specifieke combinatie voor BTC-EUR**, plus de empirische demonstratie van dominantie.

Q: “Waarom Realized Kernel en niet GARCH?” **A:** RK gebruikt **intraday data** (5-min) → veel meer signaal dan GARCH op alleen daily closes. Plus correctie voor microstructure noise.

Q: “Waarom log-RV en niet RV zelf?” **A:** (1) RV is rechts-scheef, log Gaussian; (2) lineair model op log = multiplicatief op originele schaal, past bij vol-procesgedrag.

Q: “Hoe weet je dat HAR niet overfit?” **A:** Walk-forward met 20-day refit. Training tot 2022-10, testing 2022-10 → 2026-05 (1 312 dagen onafhankelijk). DM-test p-values bevestigen niet-spuriousness.

Q: “Waarom $Z1 > 0$? Is dat goed of slecht?” **A:** Voor risk-management is conservatief beter. Het betekent een bank die HAR-ES gebruikt zou *meer* kapitaal reserveren dan strikt nodig — preferred over te weinig. Vergelijk: een te-strenge regel in regulatory finance is veiliger dan een te-soepele.

Q: “Waarom geen options-trading uitgevoerd?” **A:** Bitvavo heeft geen options markt. Voor live options-trading is Deribit nodig, minimum contract size 0.1 BTC €7000 — buiten huidige account-schaal. Onze H6-simulatie toont theoretische waarde.

Q: “Waarom MA50 + ATR-stop wint van HAR?” **A:** Trend-direction is wat directional trading vraagt; HAR voorspelt magnitude. ATR-stop gebruikt ook vol (via ATR(14)) maar in lokaler, eenvoudiger vorm. HAR’s lange-memory geheugen voegt geen waarde toe bovenop ATR’s korte-memory voor stop-placement.

16 Belangrijkste literatuur — citeer deze in je defense

- Corsi, F. (2009) — JFE 7(2). Originele HAR-paper.
- Patton, A. J., & Sheppard, K. (2015) — REStat 97(3). HAR-RS semivariance.
- Hansen, B. E. (1994) — IER 35(3). Skewed-t density.
- Acerbi, C., & Szekely, B. (2014) — Risk 27(11). ES-backtest Z1.
- Diebold, F. X., & Mariano, R. S. (1995) — JBES 13(3). DM-test.
- Barndorff-Nielsen, O. E., et al. (2008) — Econometrica 76(6). Realized Kernel.
- Moreira, A., & Muir, T. (2017) — JoF 72(4). Vol-managed portfolios.
- Basel Committee (2019) — Minimum capital requirements for market risk (FRTB).
- Christoffersen, P. F. (1998) — IER 39(4). VaR backtesting.

Klaar. Lees dit document één keer rustig door, dan ben je defendable op elk component.